

Anexos técnicos

Documento complementario de la memoria principal del Trabajo Fin de Grado. Reúne, fuera del cuerpo de la memoria, la evidencia experimental completa, los protocolos, el código esencial y los artefactos conservados del proyecto (Anexos A a J), a los que la memoria principal remite mediante referencias cruzadas de la forma «ver Anexo X del documento de anexos técnicos».

Índice de anexos

Anexo A. Inventario de artefactos del proyecto

Anexo B. Entorno de ejecución de alto rendimiento y relación completa de ejecuciones

Anexo C. Protocolos experimentales

Anexo D. Tabla maestra de resultados y resultados completos por partición

Anexo E. Galería de mapas de explicabilidad

Anexo F. ScanIA: inventario técnico del prototipo histórico

Anexo G. Instrucciones de reproducibilidad

Anexo H. Fragmentos esenciales de configuración y código

Anexo I. Tabla completa de los estudios de la revisión bibliográfica

Anexo J. Incidencia de despliegue en Cloud Run (servicio run-model)

Anexos

Los anexos que siguen documentan, con el nivel de detalle técnico que no cabe en el cuerpo del documento, la evidencia experimental, los artefactos conservados y los protocolos que sustentan el trabajo descrito en los capítulos anteriores. Cada anexo se limita a los artefactos efectivamente conservados y verificables: cuando un dato no está disponible o solo se conoce de forma indirecta, se indica explícitamente en lugar de completarlo por extrapolación.

Anexo A. Inventario de artefactos del proyecto

Este anexo presenta una relación organizada de los principales artefactos experimentales conservados a lo largo del proyecto: datos y manifiestos, particiones y protocolos, código, modelos, resultados, logs de ejecución, figuras de explicabilidad y paquetes de exportación. No es un listado exhaustivo de cada fichero individual, sino un inventario por categorías que permite ubicar, para cada bloque de evidencia citado en el cuerpo, el artefacto concreto del que procede.

Para cada artefacto se indica un estado documental, con cuatro niveles posibles:

- **Verificado directamente:** el artefacto se ha abierto y su contenido se ha inspeccionado línea a línea o campo a campo durante la elaboración de este documento.
- **Localizado:** se ha confirmado la existencia y ubicación del artefacto, pero su contenido íntegro no se ha inspeccionado en detalle.
- **Listado en paquete:** el artefacto aparece registrado en un manifiesto o listado de un paquete de exportación, sin haberse abierto de forma individual.
- **Recuperación parcial:** solo se dispone de una parte del artefacto (por ejemplo, un log truncado) o de una copia indirecta.

No se afirma que un artefacto haya sido inspeccionado directamente cuando solo consta como listado en un paquete; ambas situaciones se distinguen de forma explícita en la tabla.

A.1 Datos y manifiestos

Categoría	Artefacto	Etapa	Función	Estado documental
Datos y manifiestos	manifest_final.csv (versión reconstrucción binaria, 5872 filas)	de Reconstrucción datos	de Manifiesto maestro con patient_id real, huella SHA-256 por imagen y asignación de subconjunto (train/val/test) para las 5872 imágenes de las dos fuentes (Cheng e IXI)	Verificado directamente

Categoría	Artefacto	Etapas	Función	Estado documental
Datos manifiestos	y manifest_final.csv (copia usada en el benchmark multiclase)	Selección arquitectura	de Copia funcionalmente idéntica del manifiesto anterior (19 de 20 columnas idénticas; solo cambia la ruta local de fichero), usada como fuente para el subconjunto Cheng de 3 clases	Verificado directamente
Datos manifiestos	y dataset_audit.json dataset_audit.txt	/ Reconstrucción datos	de Auditoría automática del dataset reconstruido: totales por fuente y clase, comprobación de solapes entre subconjuntos, control de duplicados y cuantificación del sesgo de procedencia	Verificado directamente
Datos manifiestos	y split_multiclase_cheng.csv / .json	Selección arquitectura	de Split congelado de los 233 pacientes de Cheng en train/val/test, con número de cortes por paciente	Verificado directamente
Datos manifiestos	y duplicados_report.csv	Reconstrucción datos	de Informe del procedimiento de control de casi-duplicados (hashing perceptual + confirmación SSIM)	Listado en paquete
Datos manifiestos	y fuentes_pendientes.csv	Reconstrucción datos	de Registro de fuentes candidatas evaluadas y no incorporadas al dataset final	Listado en paquete
Datos manifiestos	y manifest_template.csv	Reconstrucción datos	de Plantilla de columnas del manifiesto, usada como referencia de esquema	Listado en paquete

A.2 Particiones y protocolos

Categoría	Artefacto	Etapas	Función	Estado documental
Particiones protocolos	y Split histórico 163/35/35 (train/val/test, 233 pacientes de Cheng)	Selección arquitectura y evaluación	de Partición de referencia usada de forma consistente en la selección de arquitectura y en la evaluación final	Verificado directamente

Categoría	Artefacto		Etapa		Función	Estado documental
			final		sobre el conjunto de test reservado	
Particiones protocolos	y	Protocolo de evaluación final (documento en prosa, ver Anexo C.1)	Evaluación final		Fija por escrito, antes de abrir el conjunto de test, el modelo seleccionado, la configuración de entrenamiento final y las condiciones de evaluación	Verificado directamente
Particiones protocolos	y	Plan de ajuste fino de los dos mejores candidatos (ver Anexo C.3)	Selección arquitectura	de	Fija por escrito la metodología de ajuste fino aplicada a los dos candidatos con mejor resultado en la comparación inicial	Verificado directamente
Particiones protocolos	y	Plan de combinación de modelos (ver Anexo C.4)	Selección arquitectura	de	Fija por escrito la metodología de combinación de las probabilidades de los dos modelos ajustados	Verificado directamente
Particiones protocolos	y	Protocolo de validación de robustez mediante validación cruzada de 5 particiones (ver Anexo C.2)	Validación de robustez		Fija por escrito el nuevo particionado agrupado por paciente sobre los 233 pacientes y las condiciones de esta validación complementaria	Verificado directamente
Particiones protocolos	y	Ficheros de partición de la validación cruzada de 5 particiones (partición maestra y huella de cada partición individual)	Validación de robustez		Partición estratificada y agrupada por paciente de los 233 pacientes en 5 bloques, con huella de integridad propia	Verificado directamente
Particiones protocolos	y	Documento de congelación del split y configuración históricos del modelo de referencia inicial	Histórico		Documenta el split por paciente y por corte, los identificadores exactos de los 35 pacientes del conjunto de test, y la configuración exacta del modelo de referencia inicial (arquitectura propia sin preentrenar)	Verificado directamente

A.3 Código, notebooks y scripts

Categoría	Artefacto		Etapa		Función	Estado documental
Código	y	Notebook de reconstrucción y	Reconstrucción de datos		Construye el manifiesto con <code>patient_id</code>	Verificado directamente (comparación

Categoría	Artefacto	Etapas	Función	Estado documental
notebooks	control multiclase (versión ejecutada en la reconstrucción del dataset)		real, aplica el control de duplicados y ejecuta la tarea de control de 3 clases con el modelo de referencia inicial	celda a celda con la versión corregida posteriormente)
Código y notebooks	Notebook de selección de arquitectura y comparación multiclase	Selección de arquitectura	Ejecuta el benchmark de arquitecturas, el ajuste fino, la combinación de modelos y la evaluación final sobre el conjunto de test reservado	Localizado (cobertura parcial: no se ha localizado la versión exacta que incluye todos los experimentos de ajuste fino e InceptionV3)
Código y notebooks	Script de preparación de la validación cruzada de 5 particiones	Validación de robustez	Construye el nuevo particionado agrupado y estratificado sobre los 233 pacientes	Verificado directamente
Código y notebooks	Script de ejecución de una partición individual de la validación cruzada	Validación de robustez	Entrena y evalúa el modelo sobre una partición de la validación cruzada, con seed e índice de partición como único parámetro variable	Verificado directamente
Código y notebooks	Script de agregación de resultados de la validación cruzada	Validación de robustez	Agrega los resultados de las 5 particiones, verifica la cobertura completa de los 233 pacientes y calcula las métricas globales	Verificado directamente
Código y notebooks	Scripts de generación de mapas de explicabilidad (selección de casos y generación de imágenes)	Explicabilidad	Seleccionan los casos representativos y generan las imágenes de mapas de calor sobre la última capa convolucional del modelo final	Verificado directamente (huella de integridad); código fuente no inspeccionado línea a línea
Código y notebooks	Guiones de envío al gestor de colas del clúster (uno por tipo de ejecución)	Transversal	Automatizan cada ejecución en el clúster (recursos solicitados, comando de ejecución, gestión de logs)	Verificado directamente

A.4 Modelos y checkpoints

Categoría	Artefacto	Etapas	Función	Estado documental
Modelos checkpoints	y Checkpoints de las 5 arquitecturas evaluadas en la selección inicial (3 particiones cada una)	Selección arquitectura	de Modelos con backbone congelado entrenados sobre cada una de las 3 particiones de la comparación inicial de arquitecturas	Listado en paquete (huella de integridad verificada; contenido interno del binario no inspeccionado)
Modelos checkpoints	y Checkpoints de los dos candidatos con ajuste fino	Selección arquitectura	de Modelos con las últimas 20 capas no normalizadas descongeladas, resultantes del ajuste fino de los dos mejores candidatos	Listado en paquete
Modelos checkpoints	y Checkpoint del modelo de referencia inicial (arquitectura propia, tarea de control de 3 clases)	Histórico	Modelo entrenado desde cero usado en la tarea de control histórica; no existe checkpoint separado con el mismo nombre para su reproducción posterior	Listado en paquete
Modelos checkpoints	y Checkpoint del modelo final seleccionado (arquitectura con ajuste fino, evaluado una única vez sobre el conjunto de test)	Evaluación final	Modelo final citado en el cuerpo del documento; huella de integridad verificada de forma cruzada entre el resultado de test, los ficheros de bloqueo y el listado de checkpoints	Verificado directamente (huella de integridad); binario no abierto
Modelos checkpoints	y Checkpoints de las 5 particiones de la validación cruzada de robustez	Validación robustez	de Un modelo independiente por partición, cada uno inicializado desde los pesos preentrenados originales, sin reutilizar pesos de la selección de arquitectura	Listado en paquete (huella de integridad verificada para cada partición)

A.5 Resultados (JSON/CSV)

Categoría	Artefacto	Etapas	Función	Estado documental
Resultados	Tabla resumen de la	Selección de arquitectura	Balanced accuracy, accuracy, macro-F1 y recall por	Verificado directamente

Categoría	Artefacto	Etapas	Función	Estado documental
	comparación inicial de arquitecturas		clase de las 5 arquitecturas con backbone congelado	
Resultados	Tabla resumen del ajuste fino de los dos mejores candidatos	Selección de arquitectura	Métricas de los dos candidatos tras el ajuste fino de sus últimas capas	Verificado directamente
Resultados	Tabla resumen de la combinación de modelos	Selección de arquitectura	Métricas de la combinación por promedio de probabilidades de los dos modelos ajustados, junto a las de cada modelo individual	Verificado directamente
Resultados	Resultado de la tarea de control histórica de 3 clases	Histórico	Balanced accuracy y atajo de bajo nivel del modelo de referencia inicial sobre el conjunto de test histórico	Localizado
Resultados	Resultado de la reproducción del modelo de referencia (control de regresión)	Selección de arquitectura	Métricas obtenidas al reentrenar el modelo de referencia bajo el framework reconstruido, junto con la comparación frente al resultado histórico	Verificado directamente
Resultados	Resultado de la evaluación final sobre el conjunto de test reservado	Evaluación final	Métricas completas del modelo final (balanced accuracy, accuracy, macro-F1, recall y precisión por clase, matriz de confusión, intervalo de confianza bootstrap)	Verificado directamente
Resultados	Matriz de confusión de la evaluación final (archivo independiente)	Evaluación final	Matriz de confusión del conjunto de test reservado, en formato tabular	Verificado directamente
Resultados	Análisis de los casos incorrectamente clasificados en la evaluación final	Evaluación final	Descripción detallada, con vector de probabilidad completo, de los dos pacientes del conjunto de test mal clasificados	Verificado directamente
Resultados	Resultados de validación por arquitectura (uno por modelo evaluado)	Selección de arquitectura	Métricas de validación individuales de cada arquitectura evaluada, incluida la que se incorporó en una ampliación posterior de la comparación	Verificado directamente (parcial: se ha inspeccionado el resumen agregado; no todos los ficheros individuales)

Categoría	Artefacto	Etapas	Función	Estado documental
Resultados	Resultado agregado de la validación cruzada de robustez	Validación de robustez	Métricas por partición, medias y desviaciones entre particiones, predicciones agregadas sobre los 233 pacientes y matriz de confusión agregada	Verificado directamente
Resultados	Tabla resumen por partición de la validación cruzada de robustez	Validación de robustez	Número de pacientes y cortes de entrenamiento/evaluación, métricas y huella del modelo, una fila por partición	Verificado directamente
Resultados	Predicciones por paciente y por corte (varios ficheros, uno por tipo de evaluación)	Selección de arquitectura, evaluación final y validación de robustez	Probabilidades por clase y predicción final a nivel de corte y de paciente, para las distintas evaluaciones fuera de muestra	Verificado directamente (parcial: se ha inspeccionado la estructura de columnas y una muestra de filas, no la totalidad de cada fichero)

A.6 Logs de ejecución

Categoría	Artefacto	Etapas	Función	Estado documental
Logs de ejecución	Salidas estándar y de error de la ejecución de reconstrucción y control histórico	Reconstrucción de datos	Registro completo de la ejecución que generó el dataset reconstruido y el resultado de control de 3 clases	Verificado directamente
Logs de ejecución	Salidas de los tres diagnósticos de entorno y GPU previos a la selección de arquitectura	Transversal	Confirman la disponibilidad de GPU y las variables de entorno del clúster antes de retomar los experimentos	Verificado directamente
Logs de ejecución	Salidas de las cinco ejecuciones del benchmark de arquitecturas multiclase	Selección de arquitectura	Incluyen, en una de ellas, la traza completa del aborto por control de regresión del modelo de referencia	Verificado directamente
Logs de ejecución	Salidas de la combinación de modelos, la evaluación final y la generación de	Evaluación final y	Registan el resultado final y las marcas de tiempo	Verificado

Categoría	Artefacto	Etapas	Función	Estado documental
	mapas de explicabilidad	explicabilidad	de apertura del conjunto de test reservado	directamente
Logs de ejecución	Salida de la exportación y empaquetado final de resultados	Cierre de la etapa de evaluación final	Registro de la exportación de resultados en paquetes comprimidos; el fichero disponible está truncado y no contiene una línea explícita de finalización correcta	Recuperación parcial
Logs de ejecución	Salidas de la preparación, ejecución por lotes y agregación de la validación cruzada de robustez	Validación de robustez	Registan la construcción del particionado, el entrenamiento de las 5 particiones (una subtarea por partición) y su agregación final	Verificado directamente

A.7 Figuras y artefactos de explicabilidad

Categoría	Artefacto	Etapas	Función	Estado documental
Explicabilidad	Galería completa de mapas de calor sobre la última capa convolucional (15 imágenes: 5 casos × imagen original, mapa de calor y superposición)	Explicabilidad	Analizada en detalle en el Anexo E de este documento	Verificado directamente
Explicabilidad	Tabla de metadatos de los 5 casos seleccionados para explicabilidad	Explicabilidad	Identificador de paciente, tipo de caso, clase real, clase predicha, confianza y capa utilizada para cada uno de los 5 casos	Verificado directamente
Explicabilidad	Selección de casos representativos incorporada al cuerpo del documento	Explicabilidad	Composición reducida de la galería completa, usada como figura ilustrativa en el capítulo de resultados	Verificado directamente

A.8 Paquetes y exportaciones

Categoría		Artefacto	Etapas	Función	Estado documental
Paquetes exportaciones	y	Paquete comprimido de la ejecución de reconstrucción y control histórico	Reconstrucción de datos	Contiene los notebooks, logs, resultados y manifiestos de esa ejecución	Localizado (extraído y consultado de forma selectiva)
Paquetes exportaciones	y	Paquete comprimido con la totalidad de resultados de selección de arquitectura, ajuste fino, combinación de modelos, evaluación final y explicabilidad	Selección de arquitectura, evaluación final y explicabilidad	Paquete principal del que proceden la mayoría de los artefactos citados en las secciones A.1 a A.7	Localizado (extraído y consultado de forma selectiva; no se ha inspeccionado cada fichero individual del paquete)
Paquetes exportaciones	y	Paquete comprimido de la validación cruzada de robustez	Validación de robustez	Contiene los scripts, protocolos, logs, checkpoints y resultados de las 5 particiones	Localizado (extraído y consultado de forma selectiva)
Paquetes exportaciones	y	Listados de control de los paquetes comprimidos (contenido completo del paquete, ficheros efectivamente extraídos, y checkpoints con su huella y tamaño)	Transversal	Permiten verificar qué ficheros contenía cada paquete y su huella de integridad, sin necesidad de reextraer paquetes de gran tamaño	Verificado directamente

A.9 Figura 3.4 de la memoria: trazabilidad de los ejemplos de la tarea binaria histórica

Material exclusivamente ilustrativo añadido a la memoria tras el feedback del tutor. Estos ficheros no forman parte del conjunto experimental, no sustituyen ni modifican manifest_final.csv y no intervienen en ninguna métrica ni resultado. Las huellas SHA-256 se calcularon sobre los ficheros fuente tal como se descargaron; el manifiesto registra, en cambio, la huella de los PNG derivados por el pipeline (un corte por fila), por lo que ambas huellas corresponden a artefactos distintos y no son comparables entre sí.

Campo	Panel izquierdo (tumor)	Panel derecho (sin tumor)
Dataset de origen	Cheng (Cheng et al., brain tumor dataset, Figshare)	IXI Dataset (Imperial College London, brain-development.org)
Identificador en el proyecto	CHENG-100360 (PID 100360 leído del campo cdata.PID del propio fichero; coincide con manifest_final.csv, fila original_file = 1.mat)	IXI002 (patient_id IXI-IXI002 en manifest_final.csv; volume_id IXI002-Guys-0828-T1)
Fichero fuente	1.mat (MATLAB v7.3/HDF5; imagen 512×512 int16, label = 1 meningioma, tumorMask, tumorBorder)	IXI002-Guys-0828-T1.nii.gz (NIfTI-1; 256×256×150, int16, vóxel 0,9375×0,9375×1,2 mm; modalidad T1)
Procedencia de la copia utilizada	Figshare oficial: paquete brainTumorDataPublic_1-766.zip (MD5 74b949ad33f042e6e103523091cd1428, coincidente con el publicado), DOI 10.6084/m9.figshare.1512427	Copia de terceros en Hugging Face: pzarzycki/mri-oasis-1-ixi-pre, ruta ixi_preprocessed/IXI002-Guys-0828-T1.nii.gz. El servidor oficial devolvió 403 Forbidden para IXI-T1.tar. No es el binario original del servidor IXI
Transformación conocida	Ninguna	Reorientación declarada por el autor de la copia (cabecera con sform_code = 2; orientación de ejes vóxel S-A-R). Dimensiones y tamaño de vóxel coinciden con los del volumen T1 original de IXI
SHA-256 del fichero fuente	3c237402e5181abce0b1d9e020e98ee64953cefd560f87b9d762e9e45b6547f9	bd54fc23a141ddd0f09a51a114b0b9683c94500950c286ebccdcf0e76d358c77 (.nii.gz); 4ff5a627de84e0772cccf1281c71794e5db94c18a70fa37afe54cbc2e10c577a (.nii descomprimido)
Corte mostrado	Corte único del fichero (slice_id 1)	Corte axial 150 del volumen en orientación canónica RAS, elegido tras inspeccionar los cortes 90-190 (ventrículos laterales visibles, sin estructuras faciales)
Procesado para la figura	Normalización de intensidad (percentil 99,5) a 8 bits, recorte de márgenes vacíos	Normalización de intensidad (percentil 99,5) a 8 bits, recorte de márgenes, corrección del aspecto por vóxel anisótropo
Uso	Exclusivamente ilustrativo	Exclusivamente ilustrativo

Anexo B. Entorno de ejecución de alto rendimiento y relación completa de ejecuciones

Este anexo amplía, con el detalle técnico completo, la descripción de la infraestructura de cómputo y de las ejecuciones automatizadas ya introducidas en el cuerpo del documento. Solo se documentan los recursos que constan de forma explícita en los propios registros de ejecución; cuando un recurso no está confirmado para una ejecución concreta, se indica como no documentado en lugar de generalizarlo a partir de otras ejecuciones similares.

B.1 Entorno de ejecución

Los experimentos se ejecutaron en un clúster de computación de alto rendimiento gestionado mediante un sistema de colas, bajo una cuenta de proyecto compartida y una partición de cómputo con acceso a GPU. Las ejecuciones confirmadas documentan el siguiente entorno de software:

- Python 3.10.8
- TensorFlow 2.15.1
- CUDA 12.2 (driver NVIDIA 535.54.03, confirmado en la ejecución de evaluación final)
- GPU NVIDIA A30 (24 GB), en los nodos y ejecuciones donde así se documenta explícitamente (ver tabla B.1)

No todos los campos de entorno están documentados para todas las ejecuciones. En particular, la memoria de sistema y la duración total no siempre se registran, y cuando no lo están, la celda correspondiente se deja indicada como no documentada en lugar de estimarse.

B.2 Relación completa de ejecuciones documentadas

Se documentan dieciséis identificadores de ejecución distintos, correspondientes a la reconstrucción de datos y control histórico, tres diagnósticos previos de entorno y GPU, cinco ejecuciones del benchmark de arquitecturas multiclase, y siete

ejecuciones de la fase de selección final, evaluación y validación de robustez. No se han añadido ejecuciones adicionales a esta relación más allá de las que constan documentadas en los propios registros.

Tabla B.1 — Relación completa de ejecuciones de alto rendimiento documentadas

Job ID	Etapa	Finalidad	Tipo de ejecución	GPU/recursos documentados	Artefactos/logs asociados	Observaciones
70436	Reconstrucción de datos	Reconstrucción patient-level completa del dataset y ejecución de la tarea de control histórica de 3 clases	Notebook automatizado (ejecución completa sin intervención manual)	GPU NVIDIA A30 (24 GB), nodo específico de cómputo; duración total registrada: 28 min 32 s	Salidas estándar/error de la ejecución; manifiesto y resultados de esa ejecución	Ejecución completada correctamente
70751	Diagnóstico previo	Diagnóstico de entorno general antes de retomar los experimentos	Script de diagnóstico	Sin GPU física solicitada (diagnóstico de entorno, sin recurso de GPU en la petición); duración: 1 min 24 s	Salida estándar de la ejecución	Ejecución de diagnóstico, no de cómputo del pipeline
70752	Diagnóstico previo	Diagnóstico de GPU en un nodo específico del clúster	Script de diagnóstico	GPU NVIDIA A30 confirmada explícitamente en el registro de la ejecución; duración no impresa	Salida estándar/error de la ejecución	Ejecución de diagnóstico
70754	Diagnóstico previo	Repetición del diagnóstico de GPU en el mismo nodo	Script de diagnóstico	GPU NVIDIA A30 confirmada explícitamente; duración no impresa	Salida estándar/error de la ejecución	Ejecución de diagnóstico
70885	Selección de arquitectura	Primer intento de ejecución del benchmark multiclase	Notebook automatizado	GPU NVIDIA A30 confirmada en el registro de error; sin duración de cómputo real	Salida estándar/error de la ejecución	Ejecución fallida: el notebook a ejecutar aparece vacío en este intento
70886	Selección	de Ejecución del benchmark	Notebook	GPU NVIDIA A30	Salida estándar/error de la	El control de regresión detiene la

Job ID	Etapas	Finalidad	Tipo de ejecución	GPU/recursos documentados	Artefactos/logs asociados	Observaciones
	arquitectura	multiclase con verificación de regresión del modelo de referencia	automatizado	confirmada en el registro de error; sin marca de finalización correcta	ejecución, con la traza completa del aborto por control de regresión	ejecución al detectar una diferencia superior al margen admitido respecto al resultado histórico
70887	Selección de arquitectura	Ejecución del benchmark multiclase (arquitecturas adicionales)	Notebook automatizado	GPU NVIDIA A30 confirmada en el registro de error; duración total: 21 min 26 s	Salida estándar/error de la ejecución	Ejecución completada correctamente
70888	Selección de arquitectura	Ejecución del benchmark multiclase (arquitecturas adicionales)	Notebook automatizado	GPU NVIDIA A30 confirmada en el registro de error; duración total: 9 min 24 s	Salida estándar/error de la ejecución	Ejecución completada correctamente
70891	Selección de arquitectura	Ejecución del benchmark multiclase (arquitecturas adicionales, incluida la que se incorporó en la ampliación posterior de la comparación)	Notebook automatizado	GPU NVIDIA A30 confirmada en el registro de error; duración total: 9 min 36 s	Salida estándar/error de la ejecución	El registro de esta ejecución también documenta un fallo del control de regresión que, a diferencia del job 70886, no detuvo el proceso; la causa exacta de esa diferencia de comportamiento no está confirmada en el código fuente disponible y se declara explícitamente como limitación, sin atribuirle una causa no verificada
70929	Selección de arquitectura	Combinación por promedio de probabilidades de los dos modelos ajustados	Script de post-proceso sobre resultados ya calculados	Sin evidencia de uso de GPU en los artefactos disponibles (nodo no confirmado; la propia configuración de envío no	Salida estándar de la ejecución	Ejecución muy breve, de post-proceso

Job ID	Etapas	Finalidad	Tipo de ejecución	GPU/recursos documentados	Artefactos/logs asociados	Observaciones
				solicita recursos de GPU)		
70930	Evaluación final	Entrenamiento del modelo final y evaluación única sobre el conjunto de test reservado	Notebook automatizado	GPU NVIDIA A30 solicitada explícitamente en la configuración de envío; nodo confirmado en el registro de la ejecución	Salida estándar de la ejecución (90.962 bytes); resultado completo de test	Ejecución completada correctamente; marca de tiempo de apertura del conjunto de test documentada
70931	Explicabilidad	Generación de los mapas de calor sobre la última capa convolucional para los 5 casos seleccionados	Notebook automatizado	GPU NVIDIA A30 solicitada explícitamente en la configuración de envío	Salida estándar/error de la ejecución	Ejecución completada correctamente
70932	Cierre de evaluación final	Exportación y empaquetado de resultados en paquetes comprimidos	Script de exportación	de Sin GPU solicitada (tarea de empaquetado, no de cómputo de modelo)	Salida estándar/error de la ejecución (registro truncado)	El registro disponible está truncado y no contiene una línea explícita de finalización correcta; los paquetes resultantes sí se conservan, por lo que no se afirma un fallo, solo la imposibilidad de confirmar la finalización exclusivamente a partir de este log
71101	Validación de robustez	de Construcción del nuevo particionado agrupado y estratificado sobre los 233 pacientes	Script de preparación de datos	de Sin GPU solicitada (tarea de partición de datos)	Salida estándar de la ejecución	Ejecución completada correctamente
71102	Validación de robustez	de Entrenamiento y evaluación de las 5 particiones de la validación cruzada de robustez (ejecución por lotes, una subtaska por partición, en	Notebook o script automatizado, ejecutado como lote de 5 subtaskas	GPU NVIDIA A30 confirmada explícitamente en el registro de cada subtaska; nodo confirmado mediante la configuración	Salidas estándar/error de cada una de las 5 subtaskas	No se dispone de marca de fin de la última subtaska; el tiempo de cómputo efectivo de GPU por partición (sumando las dos fases de entrenamiento) se sitúa en torno a 60-72 segundos por

Job ID	Etap	Finalidad	Tipo de ejecuci3n	GPU/recursos documentados	Artefactos/logs asociados	Observaciones
		cola secuencial)		de env3o		partici3n seg3n los propios resultados exportados, cifra distinta del tiempo total de cola del lote completo
71107	Validaci3n de robustez	Agregaci3n de los resultados de las 5 particiones de la validaci3n cruzada de robustez	Script de agregaci3n	Sin GPU solicitada (tarea de agregaci3n de resultados ya calculados)	Salida est3ndar de la ejecuci3n	Ejecuci3n completada correctamente; verifica la cobertura completa de los 233 pacientes antes de calcular las m3tricas globales

B.3 Funci3n de cada ejecuci3n

Las dieciséis ejecuciones documentadas se agrupan en cinco bloques funcionales: (i) la reconstrucci3n del dataset y el control hist3rico de 3 clases, en una 3nica ejecuci3n; (ii) tres diagn3sticos previos de entorno y disponibilidad de GPU, necesarios tras un periodo sin actividad en el cl3ster; (iii) cinco ejecuciones del benchmark de arquitecturas multiclase, que incluyen un intento fallido, una detenci3n por control de regresi3n y tres ejecuciones completadas que ampl3an progresivamente el conjunto de arquitecturas comparadas; (iv) tres ejecuciones de cierre de la selecci3n final (combinaci3n de modelos, evaluaci3n 3nica sobre el conjunto de test reservado, y generaci3n de los mapas de explicabilidad), m3s una ejecuci3n de exportaci3n de resultados; y (v) tres ejecuciones de la validaci3n de robustez mediante validaci3n cruzada de 5 particiones (preparaci3n, entrenamiento por lotes y agregaci3n).

B.4 Logs y trazabilidad

Cada una de las dieciséis ejecuciones dispone de su propio registro de salida estándar y, en la mayoría de los casos, de un registro de errores independiente, ambos conservados como artefacto primario. La comprobación de un mecanismo de copia automática de logs y artefactos al finalizar la ejecución (activado por la señal de finalización del proceso) se ha realizado de forma individual sobre los guiones de envío disponibles: de los guiones inspeccionados, únicamente el correspondiente al benchmark de arquitecturas multiclase implementa ese mecanismo; el resto de guiones inspeccionados no lo incorporan. Esta comprobación no se generaliza a guiones no inspeccionados y se limita a documentar lo verificado directamente en cada fichero.

Anexo C. Protocolos experimentales

Este anexo conserva íntegro el texto de los protocolos que se fijaron por escrito antes de ejecutar los experimentos correspondientes. Se transcribe el contenido original de cada fichero de protocolo, sin resumir ni reconstruir su contenido, precisamente para que quede constancia literal de las condiciones que se fijaron antes de observar cualquier resultado.

C.1 Protocolo de evaluación final sobre el conjunto de test reservado

Protocolo de evaluación final – tarea multiclase (glioma/meningioma/pituitario)

Modelo seleccionado

Resultado de la selección por balanced accuracy patient-level OOF (GroupCV 3-fold, train+validación, 198 pacientes):

- ResNet50 fine-tuned: 0,8853930461
- Fusión 50/50 (ResNet50-FT + InceptionV3-FT): 0,8829193293
- InceptionV3 fine-tuned: 0,8576152683

Por tanto se selecciona ResNet50 fine-tuned. No se probarán otros pesos de fusión ni configuraciones después de esta selección.

Entrenamiento final

- Cohorte: 198 pacientes (train+val) para entrenamiento; 35 pacientes de test, bloqueados durante toda la selección de arquitectura.
- Split congelado (hash): fda7e2daeb9ec2de.

Fase 1 (cabeza):

- ResNet50 preentrenado en ImageNet, backbone congelado.
- Cabeza: GAP + Dropout(0.4) + Dense(128, ReLU) + Dropout(0.3) + Dense(3, softmax).

- Adam, lr = 1e-4.
- 6 épocas (número derivado como mediana de las mejores épocas de los folds CV: [5, 9, 6]).

Fase 2 (fine-tuning):

- Últimas 20 capas no-BatchNormalization descongeladas.
- BatchNormalization congelado.
- Adam, lr = 1e-5.
- 6 épocas (número derivado como mediana de las mejores épocas de fine-tuning: [7, 3, 6]).
- Batch size: 32.
- Entrada: 224×224, RGB mediante replicación del canal de escala de grises.
- Preprocesamiento: preprocess_input de ResNet50.
- Data augmentation: mismo esquema que en el benchmark de selección.
- Semilla: 42.

Evaluación

- El conjunto de TEST se evalúa una única vez.
- Métrica principal: balanced accuracy a nivel de paciente.
- Métricas secundarias: accuracy, macro-F1, recall por clase, matriz de confusión.
- Agregación: media de probabilidades por corte a nivel de paciente, después argmax entre las 3 clases.

No se modificarán hiperparámetros después de observar TEST.

C.2 Protocolo de validación de robustez mediante validación cruzada de 5 particiones

Validación de robustez 5-fold del modelo seleccionado

Propósito

Esta fase NO realiza selección de arquitectura ni optimización de hiperparámetros.

El modelo ya seleccionado previamente mediante validación OOF sobre train+validación es:

ResNet50 con fine-tuning limitado.

La evaluación final original sobre el TEST congelado de 35 pacientes permanece inalterada y conserva su resultado:

- balanced accuracy: 0.938888889
- accuracy: 0.9428571429
- macro-F1: 0.9398282340

La presente fase proporciona una estimación interna complementaria de robustez mediante 5-fold cross-validation sobre los 233 pacientes de Cheng.

Cohorte

- Fuente: figshare/Cheng2017
- 233 pacientes
- 3064 slices
- glioma: 89 pacientes
- meningioma: 82 pacientes
- pituitario: 62 pacientes

Se combinan exclusivamente para esta validación los pacientes que pertenecían al train, validación y test del split histórico congelado.

Partición nueva

StratifiedGroupKFold:

- n_splits = 5

- groups = patient_id
- estratificación por tumor_type a nivel de paciente
- shuffle = True
- random_state = 20260904

El split histórico original NO se modifica.

Modelo y entrenamiento

Arquitectura e hiperparámetros fijados previamente:

Fase 1

- ResNet50 ImageNet
- backbone congelado
- cabeza: GAP + Dropout(0.4) + Dense(128, ReLU) + Dropout(0.3) + Dense(3, softmax)
- Adam, lr = 1e-4
- 6 épocas fijas

Fase 2

- fine-tuning limitado
- últimas 20 capas no-BatchNormalization según el mismo procedimiento del modelo final
- BatchNormalization congelado
- Adam, lr = 1e-5
- 6 épocas fijas

No se utiliza EarlyStopping para decidir el número de épocas de cada fold.

El número de épocas queda fijado antes de ejecutar la 5CV.

Semillas de entrenamiento

- fold 1: 1001

- fold 2: 1002
- fold 3: 1003
- fold 4: 1004
- fold 5: 1005

No se activa determinismo GPU estricto, manteniendo el comportamiento del protocolo experimental anterior.

Evaluación

Cada paciente aparece exactamente una vez en un fold retenido de evaluación.

Por fold:

- balanced accuracy patient-level
- accuracy patient-level
- macro-F1 patient-level
- recall por clase
- matriz de confusión
- predicciones por paciente

Resumen:

- media y desviación típica entre folds
- matriz de confusión acumulada
- métricas globales sobre las 233 predicciones OOF de pacientes

Esta 5CV es una validación interna de robustez del modelo ya seleccionado y no una validación externa independiente.

C.3 Plan de ajuste fino de los candidatos seleccionados

Fase 2B – Fine-tuning limitado multiclase

Protocolo fijado antes de ejecutar los experimentos.

Selección de candidatos

Se seleccionan exclusivamente los dos mejores backbones según balanced accuracy patient-level OOF del benchmark GroupCV:

1. ResNet50: 0.8313406171
2. InceptionV3: 0.8205782313

MobileNetV2 se conserva como alternativa eficiente, pero no se somete a fine-tuning.

Fine-tuning

- Split congelado: fda7e2daeb9ec2de
- StratifiedGroupKFold: 3 folds
- Agrupación: patient_id
- TEST: bloqueado
- Inicialización: checkpoint de base congelada correspondiente al mismo fold
- Capas descongeladas: últimas 20 capas del backbone que no sean BatchNormalization
- BatchNormalization: permanece congelado
- Cabeza clasificadora: entrenable
- Learning rate: 1e-5
- Épocas máximas: 8
- EarlyStopping: val_accuracy, mode=max, patience=3, restore_best_weights=True
- ReduceLROnPlateau: val_loss, factor=0.3, patience=2, min_lr=1e-7
- Batch size: 32
- Data augmentation: mismo esquema ya definido
- Métrica principal de selección: balanced accuracy a nivel de paciente
- Métricas secundarias: macro-F1 y recall por clase
- Agregación paciente: media de probabilidades por clase + argmax

No se probarán otros learning rates, cantidades de capas o candidatos después de observar estos resultados.

C.4 Plan de combinación de modelos

Fase 2C – Fusión multiclase

Protocolo definido antes de evaluar la fusión.

Modelos:

- ResNet50 con fine-tuning limitado
- InceptionV3 con fine-tuning limitado

Predicciones:

- exclusivamente OOF de train+val
- 3-fold StratifiedGroupKFold por patient_id
- test permanece bloqueado

Fusión única:

- soft voting 50/50
- $p_{\text{fusion}} = 0.5 * p_{\text{ResNet50}} + 0.5 * p_{\text{InceptionV3}}$

Agregación:

- media de probabilidades por paciente
- argmax entre glioma, meningioma y pituitario

Métrica principal:

- balanced accuracy a nivel de paciente

Secundarias:

- macro-F1

- accuracy
- recall por clase

No se optimizarán los pesos de la fusión después de observar el resultado.
El ganador se seleccionará por balanced accuracy patient-level OOF.

Los cuatro protocolos anteriores comparten dos rasgos: quedaron fijados por escrito antes de observar los resultados correspondientes, y ninguno se modificó después de conocer esos resultados. El protocolo de evaluación final (C.1) es el único que regula la apertura del conjunto de test reservado; los tres restantes (C.2, C.3, C.4) operan exclusivamente sobre datos de entrenamiento y validación, sin tocar ese conjunto de test.

Anexo D. Tabla maestra de resultados y resultados completos por partición

Este anexo reúne, en un único bloque, la totalidad de los resultados numéricos generados a lo largo del proyecto: el resultado histórico y su reproducción, la comparación de arquitecturas, el ajuste fino, la combinación de modelos, la evaluación final sobre el conjunto de test reservado y el detalle completo de cada una de las cinco particiones de la validación cruzada de robustez. Todas las cifras proceden de los ficheros de resultados verificados directamente y coinciden con las citadas de forma parcial en el cuerpo del documento.

D.1 Resultado histórico y su reproducción

Experimento	Balanced accuracy	Accuracy	Macro-F1	Recall glioma	Recall meningioma	Recall pituitario	Conjunto evaluado
Modelo de referencia inicial (histórico)	79,66 %	—	—	—	—	—	Test histórico (35 pacientes)
Reproducción del modelo de referencia (control de regresión)	74,44 %	77,14 %	73,33 %	83,33 %	40,00 %	100,00 %	Test (control de regresión, excepción documentada)

La diferencia entre ambos resultados (−5,21 puntos porcentuales) queda fuera del margen de tolerancia definido para el control de regresión automático, lo que provocó la detención de una de las ejecuciones del benchmark, tal como se documenta en el Anexo B.

D.2 Comparación inicial de arquitecturas (backbone congelado)

Modelo	Balanced accuracy OOF	Accuracy	Macro-F1	Recall glioma	Recall meningioma	Recall pituitario	Parámetros totales	Parámetros entrenables	Mejor época	Tiempo de entrenamiento
VGG16	78,94 %	76,77 %	75,98 %	89,61 %	47,22 %	100,00 %	14.780.739	66.051	12	52,7 s

Modelo	Balanced accuracy OOF	Accuracy	Macro-F1	Recall glioma	Recall meningioma	Recall pituitario	Parámetros totales	Parámetros entrenables	Mejor época	Tiempo de entrenamiento
ResNet50	83,13 %	81,31 %	82,06 %	79,22 %	72,22 %	97,96 %	23.850.371	262.659	12	52,5 s
MobileNetV2	81,53 %	79,29 %	79,45 %	77,92 %	66,67 %	100,00 %	2.422.339	164.355	12	33,3 s
EfficientNetB0	78,72 %	76,26 %	75,90 %	79,22 %	56,94 %	100,00 %	4.213.926	164.355	12	40,0 s
InceptionV3	82,06 %	80,30 %	80,40 %	85,71 %	62,50 %	97,96 %	22.065.443	262.659	12	39,5 s

Evaluación sobre 198 pacientes (train+validación) mediante validación cruzada agrupada de 3 particiones por patient_id, con el conjunto de test de 35 pacientes bloqueado en todo momento.

D.3 Ajuste fino de los dos mejores candidatos

Modelo	Balanced accuracy OOF	Accuracy	Macro-F1	Recall glioma	Recall meningioma	Recall pituitario
ResNet50 (fine-tuning)	88,54 %	87,37 %	88,02 %	85,71 %	81,94 %	97,96 %
InceptionV3 (fine-tuning)	85,76 %	84,34 %	84,85 %	85,71 %	73,61 %	97,96 %

D.4 Combinación de modelos

Modelo	Balanced accuracy OOF	Accuracy	Macro-F1
ResNet50 con ajuste fino	88,54 %	87,37 %	88,02 %
Combinación por promedio (ResNet50 + InceptionV3, 50/50)	88,29 %	87,37 %	87,92 %
InceptionV3 con ajuste fino	85,76 %	84,34 %	84,85 %

El modelo ResNet50 con ajuste fino obtiene la mayor balanced accuracy OOF y se selecciona como modelo final; la combinación de modelos no mejora este resultado y no se adopta.

D.5 Resultado de la evaluación final sobre el conjunto de test reservado

Métrica	Valor
Pacientes evaluados	35
Cortes evaluados	474
Balanced accuracy	93,89 %
Accuracy	94,29 %
Macro-F1	93,98 %
Recall glioma / meningioma / pituitario	91,67 % / 90,00 % / 100,00 %
Precisión glioma / meningioma / pituitario	100,00 % / 90,00 % / 92,86 %
Intervalo de confianza al 95 % (bootstrap, 2000 réplicas) — balanced accuracy	[84,26 %, 100,00 %]

Matriz de confusión (filas = clase real, columnas = clase predicha; orden glioma/meningioma/pituitario):

```
[[11, 1, 0],
 [ 0, 9, 1],
 [ 0, 0, 13]]
```

33 de 35 pacientes correctamente clasificados. Los dos errores son:

- Paciente con tumor real meningioma, predicho pituitario, con una confianza de 0,820851 (8 cortes evaluados).

- Paciente con tumor real glioma, predicho meningioma, con una confianza de 0,458572, sensiblemente más baja que la del resto de predicciones (2 cortes evaluados).

D.6 Resultados completos por partición de la validación cruzada de robustez

Partición	Pacientes entrenamiento	Pacientes evaluación	Cortes entrenamiento	Cortes evaluación	Balanced accuracy	Accuracy	Macro-F1	Recall glioma	Recall meningioma	Recall pituitario
1	186	47	2476	588	92,42 %	89,36 %	90,11 %	77,27 %	100,00 %	100,00 %
2	186	47	2448	616	82,30 %	80,85 %	80,32 %	94,12 %	61,11 %	91,67 %
3	187	46	2438	626	94,34 %	93,48 %	94,29 %	94,12 %	88,89 %	100,00 %
4	186	47	2453	611	90,07 %	89,36 %	89,43 %	100,00 %	76,47 %	93,75 %
5	187	46	2441	623	88,07 %	86,96 %	87,07 %	84,21 %	80,00 %	100,00 %
Media desviación típica	± —	—	—	—	89,44 % ± 4,64 pp	88,00 % ± 4,63 pp	88,24 % ± 5,14 pp	—	—	—

Matrices de confusión por partición (filas = clase real, columnas = clase predicha; orden glioma/meningioma/pituitario):

- Partición 1: $\begin{bmatrix} 17 & 4 & 1 \\ 0 & 14 & 0 \\ 0 & 0 & 11 \end{bmatrix}$
- Partición 2: $\begin{bmatrix} 16 & 1 & 0 \\ 2 & 11 & 5 \\ 0 & 1 & 11 \end{bmatrix}$ — composición de esta partición: 17 glioma, 18 meningioma, 12 pituitario; 38 de 47 pacientes correctos (81 % vía diagonal), la balanced accuracy más baja de las cinco particiones, por confusión principalmente entre meningioma y pituitario
- Partición 3: $\begin{bmatrix} 16 & 1 & 0 \\ 2 & 16 & 0 \\ 0 & 0 & 11 \end{bmatrix}$

- Partición 4: $[[14, 0, 0], [4, 13, 0], [1, 0, 15]]$
- Partición 5: $[[16, 3, 0], [1, 12, 2], [0, 0, 12]]$

Resultado agregado fuera de muestra sobre los 233 pacientes (cada paciente evaluado exactamente una vez, por un modelo que no lo vio en entrenamiento):

Métrica	Valor
Balanced accuracy	88,68 %
Accuracy	87,98 %
Macro-F1	88,21 %
Recall glioma / meningioma / pituitario	88,76 % / 80,49 % / 96,77 %
Pacientes correctos	205 / 233

Matriz de confusión agregada (filas = clase real, columnas = clase predicha; orden glioma/meningioma/pituitario):

```
[[79, 9, 1],
 [ 9, 66, 7],
 [ 1, 1, 60]]
```

La media de las cinco balanced accuracy por partición (89,44 %) y la balanced accuracy calculada sobre las predicciones agregadas de los 233 pacientes (88,68 %) son magnitudes distintas por construcción: la primera promedia cinco cifras ya calculadas de tamaño de muestra desigual, mientras que la segunda se calcula una sola vez sobre el conjunto completo de predicciones agregadas. Ambas cifras son coherentes entre sí, pero no intercambiables.

Esta validación cruzada de robustez es una validación interna complementaria del modelo ya seleccionado, ejecutada después de fijar la arquitectura y sin volver a tocar el conjunto de test histórico de 35 pacientes: no constituye una validación

externa sobre una cohorte independiente, ya que reutiliza los 233 pacientes de la misma fuente (Cheng), incluidos los 35 del test histórico, reagrupados en un particionado distinto.

Anexo E. Galería de mapas de explicabilidad

Este anexo documenta de forma completa la galería de mapas de calor generados mediante un método de explicabilidad post-hoc sobre la última capa convolucional del modelo final. Se incluye porque el cuerpo del documento, por razones de extensión, solo reproduce una selección reducida de casos, mientras que la galería completa (5 casos $\times$ 3 imágenes fuente = 15 PNG primarios: imagen original, mapa de calor y superposición, por paciente) constituye la evidencia íntegra que sustenta la discusión cualitativa del comportamiento del modelo en los capítulos anteriores. Para su presentación en este anexo, las tres imágenes fuente de cada caso se muestran como una única composición horizontal (imagen original, mapa de calor y superposición, de izquierda a derecha); los 15 PNG primarios que las componen se conservan sin alterar como artefactos independientes y no se ha modificado ningún píxel de su contenido.

E.1 Método y alcance

Los mapas se generaron sobre la capa convolucional final del bloque residual del modelo (identificada de forma dinámica por el propio pipeline), para cinco pacientes del conjunto de test reservado: tres clasificados correctamente (uno por cada clase) y los dos casos clasificados incorrectamente ya descritos en el Anexo D.5. Para cada paciente se generaron tres imágenes: el corte de resonancia original, el mapa de calor y la superposición de ambos.


Se insiste, como ya se advierte en el cuerpo del documento, en que este análisis es exclusivamente cualitativo y post-hoc: no se ha utilizado ninguna máscara de segmentación como referencia espacial para una evaluación cuantitativa de la superposición entre el mapa de calor y la región tumoral, por lo que las observaciones de este anexo se limitan a una descripción posicional de los mapas, sin que ello constituya una prueba de localización tumoral correcta.

E.2 Tabla de metadatos de los cinco casos

Paciente	Tipo de caso	Clase real	Clase predicha	Confianza paciente	del Corte utilizado	Probabilidad del corte en la clase predicha
CHENG-MR033389B	Acierto (glioma)	Glioma	Glioma	0,999860	2241	1,000000
CHENG-111077	Acierto (meningioma)	Meningioma	Meningioma	0,905292	588	0,999479
CHENG-105936	Acierto (pituitario)	Pituitario	Pituitario	0,999572	921	0,999972
CHENG-100572	Error	Meningioma	Pituitario	0,820851	449	0,990762
CHENG-108479	Error	Glioma	Meningioma	0,458572	858	0,616488


E.3 Galería completa (composiciones)

Caso 1 — Acierto, glioma (paciente CHENG-MR033389B, corte 2241)




Composición de las tres imágenes fuente (imagen original, mapa de calor, superposición) de este caso; las tres imágenes primarias se conservan sin alterar (ver E.1).

Caso 2 — Acierto, meningioma (paciente CHENG-111077, corte 588)




Composición de las tres imágenes fuente (imagen original, mapa de calor, superposición) de este caso; las tres imágenes primarias se conservan sin alterar (ver E.1).

Caso 3 — Acierto, pituitario (paciente CHENG-105936, corte 921)




Composición de las tres imágenes fuente (imagen original, mapa de calor, superposición) de este caso; las tres imágenes primarias se conservan sin alterar (ver E.1).

Caso 4 — Error (paciente CHENG-100572, real meningioma, predicho pituitario, corte 449)



Composición de las tres imágenes fuente (imagen original, mapa de calor, superposición) de este caso; las tres imágenes primarias se conservan sin alterar (ver E.1).

Caso 5 — Error (paciente CHENG-108479, real glioma, predicho meningioma, corte 858)



Composición de las tres imágenes fuente (imagen original, mapa de calor, superposición) de este caso; las tres imágenes primarias se conservan sin alterar (ver E.1).

E.4 Observación conjunta

En los tres casos de acierto, la confianza del modelo en la clase predicha es muy alta (superior a 0,90 en los tres, y superior a 0,999 en dos de ellos). En los dos casos de error, la confianza es sensiblemente más baja en el segundo caso (0,458572, la predicción menos segura de todo el conjunto de test), mientras que en el primer caso (0,820851) el modelo mantiene una confianza relativamente alta pese a equivocarse, lo que ilustra que una confianza alta no garantiza por sí sola un acierto. Estas observaciones son descriptivas y no sustituyen a las métricas cuantitativas ya reportadas en el Anexo D.

Anexo F. ScanIA: inventario técnico del prototipo histórico

Este anexo sustituye el resumen general de versiones anteriores de este documento por un inventario técnico explícito del prototipo de interfaz identificado en los artefactos conservados con el nombre ScanIA. Se documenta con el mismo criterio de verificación aplicado al resto del proyecto: solo se afirma lo que se ha comprobado directamente sobre los artefactos accesibles, y se declara de forma explícita lo que no se ha podido confirmar, sin completarlo por extrapolación.

F.1 Contexto histórico

ScanIA es el nombre bajo el que se identifica un conjunto de artefactos de interfaz y despliegue localizados en la misma franja horaria de trabajo, fechados el 11/07/2026, aproximadamente seis semanas antes de la reconstrucción patient-level del dataset (24/08/2026) y de la ejecución que fijó el modelo final multiclase (ResNet50 con ajuste fino, seleccionado en septiembre de 2026). Es, por tanto, cronológica y conceptualmente anterior a todo el trabajo experimental descrito en los Anexos A a E, y no se ha localizado evidencia de que se actualizara o integrara posteriormente con dicho modelo final.

F.2 Artefactos localizados

Se han localizado y verificado directamente los siguientes artefactos, todos fechados el 11/07/2026:

- Una plantilla de interfaz web (`brain_viewer.html`), con marcadores de posición para la inyección de CSS, JavaScript y datos de volumen en el servidor.
- Una hoja de estilos completa y sustancial (`brain_viewer_1.css`, aproximadamente 8.863 bytes), con variables, paneles y controles para un tema visual de tipo clínico.
- Una segunda hoja de estilos (`brain_viewer.css`) localizada como copia de 0 bytes.
- Un fichero de lógica de interacción (`brain_viewer.js`) localizado como copia de 0 bytes.

- Una definición de contenedor (`Dockerfile`) explícitamente comentada como backend de ScanIA orientado a un servicio de ejecución en la nube compatible con Cloud Run.
- Una lista de dependencias de una aplicación de escritorio (`desktop_requirements.txt`), con tres paquetes declarados: una librería de peticiones HTTP, una librería de almacenamiento en la nube de Google Cloud y una librería de procesamiento de imágenes.

Ningún otro artefacto de este prototipo se ha localizado entre los materiales accesibles más allá de los ya enumerados.

F.3 Interfaz HTML/CSS

La plantilla HTML define una interfaz de una sola pantalla, sin enrutamiento entre vistas, con campos vacíos preparados para mostrar resultados de una inferencia (por ejemplo, mejor corte, confianza máxima, puntuación media), todos con un valor inicial vacío. La hoja de estilos principal está completa y es funcionalmente coherente como CSS aislado, pero no es activable sin la lógica de interacción correspondiente. La segunda copia de la hoja de estilos y el fichero de lógica de interacción están vacíos (0 bytes) en la copia conservada; esto no permite determinar si en algún momento anterior contuvieron una versión funcional, y este documento no afirma ni descarta esa posibilidad. La visualización volumétrica 3D se apoya en la biblioteca `vtk.js`, referenciada mediante un enlace a una red de distribución de contenido externa, sin que se haya localizado código que conecte esa biblioteca con datos de volumen reales.

F.4 Inferencia NIfTI histórica

Dentro de uno de los notebooks de la etapa histórica se conserva un bloque de código real y ejecutable de inferencia sobre volúmenes en formato NIfTI (carga con una librería de lectura de neuroimagen, extracción de cortes 2D, inferencia corte a corte con el modelo y agregación mediante la regla de agregación fijada) y sobre imágenes sueltas. Este bloque está protegido por una condición explícita en el propio código que restringe su ejecución a la tarea binaria histórica (tumor/no-

tumor); nunca se ejecutó ni se adaptó a la tarea multiclase que constituye el resultado final de este trabajo. Se trata de código real, verificado directamente, pero desconectado de la interfaz descrita en el apartado F.3: ningún artefacto localizado conecta la salida de esta inferencia con la plantilla HTML ni con la variable de volumen que esta última espera recibir.

F.5 Dockerfile y configuración de despliegue

El Dockerfile conservado está explícitamente etiquetado como backend de ScanIA para Cloud Run, y define un contenedor que ejecutaría un servidor Python mediante una configuración estándar de ese servicio (variable de puerto inyectada por el entorno, comando de arranque con un servidor WSGI apuntando a una aplicación llamada `main:app`). Este documento se limita a afirmar que se conserva un Dockerfile diseñado para un despliegue compatible con Cloud Run; en ningún caso se afirma que la aplicación llegara a desplegarse. No se ha localizado evidencia de un despliegue real: no hay URL de servicio, no hay registro de una operación de despliegue, y no hay ningún identificador de proyecto de nube localizado en los artefactos accesibles.

F.6 Elementos no verificados

No se ha localizado, entre los artefactos accesibles, el código fuente del backend que el Dockerfile espera ejecutar, ni las carpetas de plantillas y de recursos estáticos que el propio Dockerfile menciona, ni el fichero de dependencias que declara copiar. Tampoco se ha localizado ninguna aplicación de escritorio nativa: la lista de dependencias conservada no implica por sí sola la existencia de una interfaz de escritorio, solo declara paquetes que podría usar un backend en Python. La dependencia de almacenamiento en la nube de Google Cloud está declarada en la lista de dependencias, pero no se ha localizado ningún fragmento de código que la utilice efectivamente en ningún artefacto accesible. Finalmente, no se ha localizado ninguna integración entre este prototipo y el modelo final multiclase (ResNet50 con ajuste fino): ni código que invoque ese modelo desde la interfaz, ni evidencia de que el prototipo se ejecutara o probara junto a él en ningún momento.

F.7 Relación con el núcleo final

ScanIA no se presenta en ningún momento de este documento como la aplicación final del proyecto ni como su producto integrador. El resultado final es el modelo de clasificación multiclase y el pipeline reproducible que lo sustenta, documentados en el cuerpo del documento y en los Anexos A a E. ScanIA es un componente exploratorio e histórico, desacoplado del núcleo experimental final tanto en el tiempo (aproximadamente seis semanas de antelación) como en el alcance de la tarea: su única pieza de inferencia real está ligada a una clasificación binaria (tumor/no-tumor), no a la clasificación multiclase de tres tipos de tumor que constituye el resultado final de este trabajo.

Tabla F.1 — Inventario técnico de artefactos de ScanIA

Artefacto	Estado	Qué permite afirmar	Qué no permite afirmar
Plantilla de interfaz web (HTML)	Localizado, directamente	verificado Existencia de un diseño de interfaz de una sola pantalla, con campos preparados para mostrar resultados de inferencia	Que la interfaz llegara a mostrar resultados de una ejecución real
Hoja de estilos principal (CSS)	Localizado, directamente, sustancial	verificado contenido Existencia de un diseño visual completo y coherente como hoja de estilos aislada	Que la interfaz fuera visualmente funcional sin la lógica de interacción, ausente
Segunda copia de la hoja de estilos	Localizado, copia de 0 bytes	Que existió (o se previó) un segundo fichero de estilos	Su contenido original, si lo tuvo
Fichero de lógica de interacción (JavaScript)	Localizado, copia de 0 bytes	Que existió (o se previó) un fichero de lógica de interacción	Que la interfaz tuviera en algún momento interactividad real; tampoco descarta que la tuviera
Biblioteca de visualización 3D (vtk.js)	Referenciada mediante enlace externo (CDN)	Que se previó una visualización volumétrica basada en esa biblioteca	Que esa visualización llegara a conectarse con datos reales
Dockerfile de despliegue	Localizado, verificado	Que se diseñó un contenedor compatible con	Que ese contenedor llegara a construirse

Artefacto	Estado	Qué permite afirmar	Qué no permite afirmar
	directamente	un despliegue en Cloud Run	o desplegarse
Lista de dependencias de escritorio	Localizado, verificado directamente	Que se declararon tres dependencias de Python para un posible backend o aplicación	Que exista una aplicación de escritorio nativa que las use
Inferencia NIfTI/imagen suelta (código en notebook)	Localizado, verificado directamente, código real y ejecutable	Que existió una inferencia funcional sobre volumen NIfTI y sobre imagen suelta, exclusiva de la tarea binaria histórica	Que esa inferencia estuviera conectada a la interfaz de ScanIA o al modelo multiclase final
Backend del servidor (código de la aplicación)	No localizado	—	Que el backend descrito en el Dockerfile llegara a implementarse
Carpetas de plantillas y recursos estáticos del backend	No localizadas	—	Que existiera el resto de la aplicación web más allá de la plantilla HTML aislada
Uso efectivo de almacenamiento en la nube (Google Cloud)	Dependencia declarada, sin código de uso localizado	Que se previó usar ese servicio	Que llegara a usarse efectivamente
Integración con el modelo final (ResNet50 con ajuste fino)	No localizada	—	Que ScanIA se conectara en algún momento con el modelo final multiclase

Con base en este inventario, el estado de ScanIA se documenta como completo con reservas: los artefactos de diseño e infraestructura conservados son reales y se describen con precisión, pero varias piezas necesarias para una aplicación funcional (backend, integración con el modelo final, confirmación de despliegue) no se han localizado ni pueden confirmarse con la evidencia disponible. No se incluye una representación visual del prototipo en este anexo por no disponer de una renderización fiel verificable de la interfaz a partir de los artefactos conservados; incluir una reconstrucción visual no verificada introduciría un elemento no respaldado por evidencia directa.

Anexo G. Instrucciones de reproducibilidad

Este anexo describe, a partir exclusivamente de los protocolos, configuraciones y huellas de integridad ya documentados en los anexos anteriores, la secuencia de pasos que reproduciría los experimentos de este trabajo. No introduce ninguna decisión metodológica nueva: se limita a ordenar y hacer explícitas las condiciones ya fijadas en los Anexos B y C.

G.1 Entorno necesario

- Python 3.10.8, TensorFlow 2.15.1, CUDA 12.2, sobre una GPU NVIDIA A30 (24 GB) o equivalente compatible con esa versión de CUDA.
- Acceso a un sistema de colas de un clúster de alto rendimiento, con capacidad de solicitar recursos de GPU por ejecución.
- Los dos conjuntos de datos de origen: la colección de Cheng et al. (resonancias con contraste, 233 pacientes, 3 tipos de tumor) y, si se desea reproducir también la reconstrucción histórica completa, la colección IXI (resonancias sin contraste, usada únicamente en la tarea binaria histórica).

G.2 Orden de ejecución

1. **Reconstrucción del dataset:** construir el manifiesto con identificador de paciente real a partir de las fuentes originales, aplicar el control de duplicados por huella exacta (SHA-256) y casi-duplicado (hashing perceptual con confirmación por índice de similitud estructural), y verificar mediante comprobaciones automáticas la ausencia de solapamiento de pacientes entre subconjuntos. El resultado de esta reconstrucción debe verificarse contra las huellas documentadas en el Anexo A.1 antes de continuar.

2. **Congelación del split multiclase:** fijar el split de 233 pacientes de Cheng en 163/35/35 (train/val/test) y verificar que la huella del split coincide con la documentada en el Anexo A.2. El conjunto de test (35 pacientes) debe permanecer sin abrir a partir de este punto.
3. **Selección de arquitectura:** evaluar, mediante validación cruzada agrupada de 3 particiones por paciente sobre los 198 pacientes de train+validación, las arquitecturas y configuraciones documentadas en el Anexo D.2, sin tocar en ningún momento el conjunto de test.
4. **Ajuste fino:** aplicar el protocolo del Anexo C.3 exclusivamente a los dos candidatos con mejor resultado en el paso anterior.
5. **Combinación de modelos:** aplicar el protocolo del Anexo C.4 sobre los dos modelos ajustados, y comparar su resultado con el del mejor modelo individual.
6. **Selección final:** seleccionar como modelo final el candidato (individual o combinado) con mayor balanced accuracy fuera de muestra en los pasos 3 a 5, sin volver a probar configuraciones adicionales tras esta selección.
7. **Fijación del protocolo de evaluación final por escrito:** redactar y conservar con huella de integridad el protocolo del Anexo C.1, antes de abrir el conjunto de test.
8. **Evaluación final única:** entrenar el modelo final sobre los 198 pacientes con la configuración fijada en el Anexo C.1, y evaluarlo una única vez sobre los 35 pacientes de test, sin modificar ningún hiperparámetro después de observar el resultado.
9. **Explicabilidad:** generar los mapas de calor sobre la última capa convolucional del modelo final para los casos seleccionados, según se describe en el Anexo E.
10. **Validación de robustez:** aplicar el protocolo del Anexo C.2 sobre los 233 pacientes de Cheng (reagrupando los del split histórico en un nuevo particionado de 5 bloques), entrenando un modelo independiente por partición desde los pesos preentrenados originales, sin reutilizar los modelos de los pasos anteriores.

G.3 Verificaciones de integridad recomendadas en cada paso

En cada uno de los pasos anteriores, antes de aceptar cualquier resultado como válido, conviene verificar de forma automática: la ausencia de solapamiento de identificadores de paciente entre los subconjuntos implicados en ese paso; la coincidencia de la huella del manifiesto, del split y de la configuración con los valores documentados en el Anexo A; y, cuando exista un resultado histórico de referencia (como en el paso 1, para la tarea de control histórica de 3 clases), la comparación automática contra ese resultado con un margen de tolerancia fijado de antemano, deteniendo la ejecución si la diferencia lo supera, tal como se describe en el Anexo B.2 para una de las ejecuciones del benchmark de arquitecturas.

G.4 Advertencia sobre el determinismo

La configuración documentada no activa un modo de determinismo estricto de la GPU. Esto significa que, incluso reproduciendo exactamente el mismo split, la misma configuración y la misma semilla, una reejecución sobre GPU puede no reproducir de forma exacta la última cifra decimal de cada métrica, si bien debería aproximarse de forma cercana si el resto de la implementación es equivalente. Esta es una limitación conocida del entorno de ejecución, no un fallo del protocolo.

Anexo H. Fragmentos esenciales de configuración y código

Este anexo recoge, de forma literal, un conjunto reducido de fragmentos de código y de configuración que resultan esenciales para entender exactamente cómo se calculan las métricas y se ejecutan los experimentos citados en el cuerpo del documento. No pretende ser una reproducción completa del código del proyecto, sino los fragmentos mínimos necesarios para eliminar cualquier ambigüedad sobre su funcionamiento exacto.

H.1 Agregación de la predicción a nivel de paciente

Todas las evaluaciones patient-level de este trabajo (selección de arquitectura, evaluación final y validación de robustez) usan la misma regla de agregación: la media aritmética de las probabilidades por clase de todos los cortes de un paciente, seguida de la clase con mayor probabilidad media.

```
pac3 = ap_te[["patient_id", "tumor_type"]].copy()
for i, t in enumerate(TIPOS):
    pac3[f"p_{t}"] = P[:, i] # prob. de cada slice, por clase
agr = pac3.groupby("patient_id").agg(**{f"p_{t}": "mean" for t in TIPOS},
                                     "tumor_type": "first"})
pred_pac = agr[[f"p_{t}" for t in TIPOS]].values.argmax(1) # argmax de la media
real_pac = agr["tumor_type"].map(MAPA_TIPO).values
bal_pac = balanced_accuracy_score(real_pac, pred_pac) # sklearn, multiclase
```

Es importante señalar que la función `balanced_accuracy_score` de la biblioteca científica utilizada, en su modo multiclase, calcula la media del recall por clase; esta es la definición estándar para más de dos clases y es distinta de la fórmula de sensibilidad/especificidad habitual en la tarea binaria histórica. Ambas se denominan "balanced accuracy" pero no son la misma fórmula, lo cual es relevante al comparar cifras entre la tarea histórica y la tarea multiclase final.

H.2 Arquitectura de la cabeza clasificadora

Configuración común a todos los modelos preentrenados con transferencia de aprendizaje (selección de arquitectura, ajuste fino, modelo final y las cinco particiones de la validación de robustez):

GAP (Global Average Pooling)

-> Dropout(0.4)

-> Dense(128, activación ReLU)

-> Dropout(0.3)

-> Dense(3, activación softmax)

Compilación: optimizador Adam, función de pérdida `sparse_categorical_crossentropy`. En la fase de cabeza (backbone congelado), tasa de aprendizaje $1e-4$; en la fase de ajuste fino (últimas 20 capas no de normalización por lotes descongeladas, con las capas de normalización por lotes congeladas), tasa de aprendizaje $1e-5$. Tamaño de lote: 32 en todas las fases.

H.3 Bloque de huellas de integridad del split multiclase

SPLIT_HASH_MULTICLASE (16 caracteres):

fda7e2daeb9ec2de

SPLIT_HASH_MULTICLASE (SHA-256 completo):

fda7e2daeb9ec2de596e807728454329cd140398dd10f834599457eca86c0092

Hash del manifiesto Cheng (local_file, patient_id, tumor_type, subset, sha256), 16 caracteres:

a78633a95254d7c2

SHA-256 completo del manifiesto usado como fuente:

c468eb4e057dfab9b883b73c59e959f6194b0c46037df6b7cef22c9b2e5e6487

(5872 filas totales, 3064 filas correspondientes a Cheng)

Huellas del dataset completo de referencia (467 pacientes, 5872 imágenes):

```
manifest_hash = b6881df313b8c6b5  
split_hash    = 81d2b363fa9c274a  
config_hash   = b67c4e3262df5b24
```

Cualquier reejecución que cargue este split debe recalcular la huella sobre el manifiesto vigente y detenerse si no coincide con el valor documentado, en lugar de regenerar un reparto nuevo.

H.4 Mecanismo de control de regresión del modelo de referencia

El pipeline incorpora una comprobación automática que compara la balanced accuracy reproducida del modelo de referencia histórico con el valor histórico conservado (79,66 %), deteniendo la ejecución mediante una excepción no capturada si la diferencia absoluta supera un margen de tolerancia de $\pm 0,03$. Esta comprobación se activó efectivamente en una de las ejecuciones (diferencia observada: -5,21 puntos porcentuales, fuera de tolerancia), documentada en el Anexo B.2. En una ejecución distinta, la misma comprobación registró un resultado fuera de tolerancia sin que la ejecución se detuviera; la causa exacta de esa diferencia de comportamiento entre ambas ejecuciones no está confirmada en el código fuente disponible y se documenta como limitación abierta, sin atribuirle una causa no verificada.

H.5 Configuración de una ejecución con GPU en el sistema de colas

Fragmento representativo (correspondiente a la ejecución de evaluación final) de la configuración de recursos usada para las ejecuciones que requieren GPU:

```
#SBATCH --partition=main  
#SBATCH --gres=gpu:a30:1  
#SBATCH --nodelist=gpu02  
#SBATCH --cpus-per-task=8  
#SBATCH --mem=64G  
#SBATCH --time=02:00:00
```

Esta configuración no es idéntica para todas las ejecuciones documentadas en el Anexo B: las ejecuciones de post-proceso o de agregación de resultados, que no requieren cómputo de red neuronal, se enviaron sin solicitud de GPU y con recursos de memoria y tiempo sensiblemente menores, como se detalla en la Tabla B.1.

H.6 Particiones agrupadas por paciente

Todas las particiones de este trabajo —la validación cruzada agrupada de 3 particiones usada en la selección de arquitectura (198 pacientes de train+validación) y la validación cruzada estratificada y agrupada de 5 particiones usada en la validación de robustez (233 pacientes)— se construyen agrupando por `patient_id`, de forma que ningún paciente aparece simultáneamente en el conjunto de entrenamiento y en el conjunto de evaluación de una misma partición. Ambos particionados son distintos entre sí: el primero opera sobre 198 pacientes con el conjunto de test de 35 pacientes bloqueado en todo momento y tiene como propósito exclusivo la selección de arquitectura; el segundo opera sobre los 233 pacientes de la cohorte completa de Cheng (incluidos los 35 del test histórico, reagrupados) y tiene como propósito exclusivo una estimación interna complementaria de robustez del modelo ya seleccionado. Ninguno de los dos particionados sustituye o modifica al otro, y ninguno constituye una validación cruzada anidada del otro.

H.7 Controles de integridad y asserts

El pipeline incorpora varios mecanismos de verificación automática que se ejecutan antes de aceptar un resultado como válido:

- **Disjunción de ``patient_id``:** comprobación automática de que ningún identificador de paciente aparece simultáneamente en dos subconjuntos de una misma partición (train/validación/test, o entre folds de una validación cruzada).
- **Cobertura completa de pacientes:** verificación de que la agregación de resultados de la validación cruzada de robustez cubre exactamente los 233 pacientes de la cohorte, sin duplicados ni ausencias, antes de calcular las métricas globales.


- **Huellas de integridad (hashing):** cálculo y verificación de huellas SHA-256 sobre manifiestos, splits y configuraciones, de forma que una reejecución que cargue estos artefactos debe recalcular su huella y detenerse si no coincide con el valor documentado, en lugar de regenerar un reparto nuevo.
- **Verificación de parámetros del modelo:** comprobaciones sobre el número de parámetros totales y entrenables de cada arquitectura evaluada, como control adicional de que la configuración cargada corresponde a la esperada.
- **Control de regresión del modelo de referencia:** comparación automática de la balanced accuracy reproducida del modelo de referencia histórico frente al valor histórico conservado, deteniendo la ejecución si la diferencia supera el margen de tolerancia fijado, tal como se documenta en el Anexo H.4.

Estos mecanismos son los únicos controles de integridad automatizados documentados con evidencia directa en el código y en los registros de ejecución disponibles; no se afirma la existencia de ningún otro mecanismo de control no verificado.

H.8 Esquemas conceptuales complementarios

Los siete esquemas siguientes resumen de forma visual, sin introducir información nueva respecto a los apartados anteriores de este anexo y del cuerpo del documento, el flujo general del pipeline, el preprocesamiento, la cabeza de clasificación, la agregación a nivel de paciente, el flujo de generación de los mapas de explicabilidad, y los dos particionados agrupados por paciente descritos en el Anexo H.6.

Figura H.1 — Flujo general del pipeline




Esquema del flujo de datos y control interno del pipeline de entrenamiento y evaluación, limitado a las etapas de datos, configuración, preprocesamiento, modelo, predicciones, agregación por paciente, métricas y artefactos/logs; no incluye ningún componente de interfaz, API, despliegue en la nube ni base de datos, por no formar parte del núcleo experimental final.

Figura H.2 — Flujo de preprocesamiento de imagen




Secuencia de preprocesamiento aplicada a cada corte de resonancia magnética antes de su entrada al modelo: recorte de la caja del cerebro, normalización por percentiles 1-99, redimensionado a 224x224 y replicación a 3 canales, seguida del preprocesamiento propio de la arquitectura.

Figura H.3 — Cabeza de clasificación




Esquema de la cabeza clasificadora común a todas las arquitecturas con transferencia de aprendizaje de este trabajo, ya descrita textualmente en el Anexo H.2: GAP, Dropout(0.4), Dense(128, ReLU), Dropout(0.3) y Dense(3, softmax).

Figura H.4 — Agregación de la predicción a nivel de paciente



Representación del mecanismo de agregación descrito textualmente en el Anexo H.1: media aritmética de las probabilidades por clase de todos los cortes de un mismo paciente, seguida de la clase de mayor probabilidad media (argmax).


Figura H.5 — Flujo de generación de los mapas de explicabilidad



Análisis cualitativo post-hoc (no segmentación)


Flujo de generación de los mapas de calor documentados en el Anexo E: desde la imagen y el modelo final hasta el mapa de activación, el mapa de calor y la superposición. Se marca explícitamente como un análisis cualitativo post-hoc, no como un método de segmentación.

Figura H.6 — Validación cruzada agrupada de 3 particiones (selección de arquitectura)



Esquema del particionado agrupado por `patient_id` en 3 folds sobre los 198 pacientes de train+validación, usado exclusivamente para la selección de arquitectura, con los 35 pacientes del conjunto de test bloqueados durante todo el proceso.

Figura H.7 — Validación cruzada agrupada de 5 particiones (validación de robustez)



Esquema del particionado `StratifiedGroupKFold` de 5 folds por `patient_id` sobre los 233 pacientes de la cohorte completa de Cheng, con la arquitectura ya fijada previamente (sin validación cruzada anidada). Se marca explícitamente como una validación interna posterior, no como una validación externa sobre una cohorte independiente.

Anexo I. Tabla completa de los estudios de la revisión bibliográfica

Este anexo recoge la totalidad de los estudios identificados en la revisión bibliográfica estructurada realizada como apoyo al capítulo de estado del arte. La revisión no siguió un protocolo formal de revisión sistemática y se documenta como tal. De un total de 39 estudios distintos, únicamente cuatro se citan por nombre en el cuerpo del documento como comparadores aplicados, por ser los únicos verificados directamente contra su fuente original en el momento de redactar este trabajo; el resto se incorpora aquí con su estado de verificación indicado de forma explícita, sin excepciones, y ninguno se ha eliminado de esta tabla por permanecer pendiente de verificación.

Esquema de columnas: Estudio | Dataset | Tarea | Arquitectura | Split | Tipo de control | Métrica | Estado de verificación.

I.1 Estudios con partición no especificada suficientemente o a nivel de imagen (29 estudios)

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
Noreen et al. (2020)	Figshare/Cheng, 3 clases	Clasificación de tipo de tumor	Inception-v3 / DenseNet201, concatenación multinivel	No especificado	Ninguno confirmado	99,34 % (Inception-v3) / 99,51 % (DenseNet201)	Pendiente verificación artículo original
Karim, Mahmood y Sah (2023)	Figshare, 3 clases	Clasificación de tipo de tumor	CNN propia + ResNet50 (transferencia) + SVM	No especificado	Ninguno confirmado	99,35 % (CNN+SVM) / 99,61 % (ResNet50+SVM)	Pendiente verificación artículo original
Kakarla et al. (2021)	Figshare, 3064 imágenes, 3 clases	Clasificación de tipo de tumor	CNN de 8 capas con average-pooling	No especificado	Ninguno confirmado	97,42 %	Pendiente verificación artículo original
Mulla y Direkoglu (2023)	Figshare, 3 clases	Clasificación de tipo de tumor	VGG-16, varios optimizadores	70/15/15, no a nivel de paciente	Ninguno confirmado	97,15 % (test)	Pendiente verificación artículo original

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
Minarno et al. (2025)	Figshare/Cheng, 3064 imágenes / 233 pacientes, 3 clases	Clasificación de tipo de tumor	CNN propia	No especificado	Ninguno confirmado	98,30 %	Pendiente verificación artículo original
Alaeddine y Neji (2025)	Figshare, 3 clases	Clasificación de tipo de tumor	CNN mejorada (E-CNN)	No especificado	Ninguno confirmado	97,14 %	Pendiente verificación artículo original
Hmidi, Kouka y Tekari (2025)	Figshare/Cheng, 3064 imágenes / 233 pacientes, 3 clases	Clasificación de tipo de tumor	CNN ligera con ajuste fino (orientada a dispositivo embebido)	No especificado	Ninguno confirmado	94,08 %	Pendiente verificación artículo original
Haq et al. (2023)	Figshare (3062 imágenes) + BraTS2018	Clasificación de tipo de tumor y segmentación	CNN profunda + campo aleatorio condicional	No especificado	Ninguno confirmado	97,3 % (3 clases); coeficiente de Dice 95,8 %	Pendiente verificación artículo original
Divya et al. (2023)	Figshare, 3 clases	Clasificación de tipo de tumor	ResNet50 (transferencia) + clasificador híbrido (algoritmo firefly)	No especificado	Ninguno confirmado	99 % (modelo híbrido)	Pendiente verificación artículo original
Nizamani et al. (2025)	Figshare + Br35H	Clasificación de tipo de tumor	Fusión EfficientNetB0 + MobileNetV2 (LiteNet)	No especificado	Ninguno confirmado	99,02 % (Figshare) / 99,83 % (Br35H)	Pendiente verificación artículo original
Chen et al. (2024)	Figshare (DS1) + Kaggle (DS2)	Clasificación de tipo de tumor	Fusión ResNet101 + DenseNet121 + EfficientNetB0	No especificado	Ninguno confirmado	99,18 % (Figshare) / 97,24 % (Kaggle)	Pendiente verificación artículo original
Karpakam y Kumareshan (2025)	Figshare + otros (RM y radiografía)	Clasificación de tipo de tumor	Red generativa adversarial híbrida con atención (DIR-GAN)	No especificado	Ninguno confirmado	98,90 % (Figshare)	Pendiente verificación artículo original
Sadr et al. (2025)	Figshare (3064) /	Clasificación de	CNN de 26 capas +	No especificado	Ninguno	97,27 % / 97,14–98,57 % / 100 %	Pendiente

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
	Br35H (3000) / Harvard (152)	tipo de tumor	VGG16/Xception (transferencia)		confirmado	(según dataset)	verificación artículo original
Ahmed et al. (2025)	Kaggle (6217 imágenes, 4 clases) y Figshare (3064 imágenes, 3 clases), por separado	Clasificación de tipo de tumor	CNN híbrida (VGG16 + CNN propia)	No especificado	Ninguno confirmado	95,12 % (Kaggle) / 95,31 % (Figshare)	Pendiente verificación artículo original
Murugan, Govindaraj y Prince (2026)	No especificado, 4 clases	Clasificación de tipo de tumor	CNN con transferencia de aprendizaje	No especificado	Ninguno confirmado	Sin cifra disponible en el resumen consultado	Pendiente verificación artículo original
Sanchez-Moreno et al. (2025)	No especificado, 4 clases (incluye clase "benigno")	Clasificación de tipo de tumor con explicabilidad	Combinación de VGG16 + DenseNet121 + Inception-ResNet-v2, con módulo de explicabilidad	No especificado	Ninguno confirmado	86,17 % (combinación)	Pendiente verificación artículo original
Sharma y Mittal (2024)	Dataset tipo Kaggle, 7523 imágenes, 4 clases	Clasificación de tipo de tumor	CNN optimizada	No especificado	Ninguno confirmado	Hasta 99 %	Pendiente verificación artículo original
Delvadiya, Hakani y Hakani (2026)	No especificado, 4 clases	Clasificación de tipo de tumor	ResNet50 / VGG16 / EfficientNetB2 / InceptionV3 (transferencia) + cabeza densa	No especificado	Ninguno confirmado	98,77 % (ResNet50 y VGG16)	Pendiente verificación artículo original
Pandiyarajan et al. (2024)	No especificado	Clasificación de tipo de tumor	CNN	No especificado	Ninguno confirmado	95 %	Pendiente verificación

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
							artículo original
Gupta et al. (2021)	No especificado, 4 clases	Clasificación de tipo de tumor	de Tres arquitecturas CNN distintas (una de tipo VGG16)	No especificado	Ninguno confirmado	91,29 % / 79,79 % / 87,27 %, según arquitectura	Pendiente verificación artículo original — no localizado en esta revisión
JeyaPriya, Avinash y Dinesh (2025)	Kaggle Msoud, 7023 imágenes, 4 clases	Clasificación de tipo de tumor	de CNN con ajuste de hiperparámetros	No especificado	Ninguno confirmado	99,4 % (media)	Pendiente verificación artículo original
Agrawal et al. (2024)	Dataset desbalanceado no especificado, 3 clases	Clasificación de tipo de tumor	de Comparativa de 10 modelos de aprendizaje profundo	No especificado	Ninguno confirmado	Sin cifra única en el resumen consultado	Pendiente verificación artículo original
Asif et al. (2023)	No especificado, 3 y 4 clases	Clasificación de tipo de tumor	de Xception / DenseNet / ResNet / InceptionResNet + bloque denso adicional	No especificado	Ninguno confirmado	99,67 % (3 clases) / 95,87 % (4 clases)	Pendiente verificación artículo original
Verma y Singh (2022)	No especificado, 3 clases	Clasificación de tipo de tumor	de 8 arquitecturas × 5 configuraciones (40 modelos comparados)	No especificado	Ninguno confirmado	98,22 % (DenseNet201) / 97,87 % (MobileNet)	Pendiente verificación artículo original
G.S. y V.J. (2026)	No especificado, 3 y 4 clases	Clasificación de tipo de tumor	de Transferencia de aprendizaje híbrida (Xception, ResNet164, DenseNet121/201, Inception-ResNetV2)	No especificado	Ninguno confirmado	99,71 % (3 clases) / 96,17 % (4 clases)	Pendiente verificación artículo original
M S. et al. (2024)	6 datasets de Kaggle	Clasificación de tipo de tumor	de MobileNetV2	No especificado	Ninguno confirmado	99,38 % (3 clases: meningioma/pituitario/glioma)	Pendiente verificación

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
	combinados						artículo original
Khemariya y Sonker (2025)	4569 imágenes, 4 clases	Clasificación de tipo de tumor	de Transferencia aprendizaje	de No especificado	Ninguno confirmado	99,93 % (entrenamiento) / 98,1 % (test)	Pendiente verificación artículo original
Ashvinbhai, Dixit y Hazra (2025)	Dataset tipo Figshare, 3 clases	Clasificación de tipo de tumor	de ResNet++ frente a DenseNet121	a 70/15/15, no a nivel de paciente	Ninguno confirmado	94 % (ResNet++) / 90 % (DenseNet121)	Pendiente verificación artículo original
Mallouk, Joudar y Ettaouil (2026)	Imágenes de resonancia magnética, 3 clases	Clasificación de tipo de tumor	de Transferencia aprendizaje con regularización L1	de No especificado con	Ninguno confirmado	Sin cifra disponible en el resumen consultado	Pendiente verificación artículo original

I.2 Estudios con control explícito de independencia entre muestras (10 estudios)

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
Bulla, Anantha y Peram (2020)	Figshare/ Cheng, 3064 imágenes / 233 pacientes, 3 clases (mismo dataset que este trabajo)	Clasificación de tipo de tumor	InceptionV3 (transferencia), comparando nivel de imagen frente a nivel de paciente	Holdout / 10-fold / 10-fold estratificado / 10-fold agrupado por paciente	Patient-level explícito	99,82 % de accuracy (no balanced accuracy) en el esquema agrupado por paciente, el más alto de los cuatro esquemas probados	Verificado directamente contra la fuente original — citado por nombre en el cuerpo
Nalawade et al.	TCIA, 260 sujetos (tarea)	Predicción de estado	CNN 2D densamente conectada	Validación cruzada de 5	Patient-level explícito (a	90,5 % por corte frente a 83,8 % por	Verificado directamente

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
(2019)	de mutación IDH, no de tipo de tumor)	mutacional		particiones, separación de sujetos explícita	nivel de sujeto)	de sujeto (cifra realista)	e contra la fuente original — citado por nombre en el cuerpo
Hassan et al. (2026)	Dataset propio + validación externa (aprox. 3000 imágenes)	Clasificación tumor/no-tumor	InceptionV3 + optimizador Nadam	Validación cruzada estratificada de 5 particiones patient-wise sobre el 90 % de los datos, 10 % restante como test independiente	Patient-level explícito + validación externa	98,3 % $\pm$ 0,9 % (interno); 96 % (externo)	Verificado directament e contra la fuente original — citado por nombre en el cuerpo
Arghistani , Erbay y Ozdil (2026)	Kaggle, 7023 imágenes, 4 clases	Clasificación de tipo de tumor	Red multi-rama con bloques de atención (PMS-Net)	70/15/15, con deduplicación por huella exacta y perceptual	Deduplicación, sin patient-level confirmado (los propios autores señalan la ausencia de partición real a nivel de paciente)	97,10 % (test)	Verificado directament e contra la fuente original — citado por nombre en el cuerpo
Ali et al. (2026)	15.000 imágenes	Clasificación de tipo de	Xception / InceptionV3 / ConvNeXtBase / DenseNet169	Validación cruzada	Patient-level	0,96–0,98 (Xception/InceptionV	Pendiente verificación

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
	multicorte, 3 clases	tumor		patient-wise explícita	explícito	3); hasta aprox. 0,999 (DenseNet169)	artículo original
Islam, Shill e Iqbal (2026)	875 imágenes, 4 clases	Clasificación de tipo de tumor	Combinación de EfficientNetB4/MobileNetV3/MobileNetV2/EfficientNetB0	Validación cruzada de 5 particiones + test independiente	Nivel de paciente no especificado	98,76 % (mejor, MobileNetV3); por debajo del 80 % (MobileNetV2)	Pendiente verificación artículo original
Lu, Zhang y Chaudhar y (2026)	Dataset depurado de duplicados (3522 cortes únicos)	Clasificación de tipo de tumor	Transformador con atención multi-token (MTA-Swin)	Deduplicación exhaustiva antes del split	Deduplicación, no necesariament e patient-level	98,57 % (media de 3 semillas)	Pendiente verificación artículo original
Jing, Xu y Chen (2025)	Dataset depurado (control de duplicados por huella y similitud de características)	Clasificación de tipo de tumor con explicabilidad	ResNet50 + módulos de explicabilidad	Limpieza rigurosa anti-duplicados, nivel de paciente no especificado	Deduplicación, nivel de paciente no especificado	97,62 % de accuracy; 97,58 % de F1 macro	Pendiente verificación artículo original
Saifullah, Baldauf y Sakumura (2025)	Dataset público sin metadatos de paciente	Clasificación de tipo de tumor	EfficientNetB0 / InceptionV3	Deduplicación por hash perceptual + splits estratificados + validación cruzada anidada	Deduplicación + validación cruzada, sin metadatos de paciente	Caída ligera de accuracy tras eliminar duplicados (cifra exacta no disponible en el resumen consultado)	Pendiente verificación artículo original
Al Hassan	Dos datasets	Clasificación y	Framework multitarea diseñado para evitar fuga de	Separación	Validación	94,2 % (test interno) /	Pendiente

Estudio	Dataset	Tarea	Arquitectura	Split	Tipo de control	Métrica	Estado de verificación
et al. (2026)	públicos independientes (uno interno, otro externo)	segmentación multitarea	información	estricta train/val/test + validación externa	externa multi-dataset (independencia entre datasets, no necesariamente patient-level dentro de cada uno)	99,1 % (test externo)	verificación artículo original

I.3 Síntesis

De los 39 estudios recopilados, cuatro (Bulla et al., Nalawade et al., Hassan et al. y Arghistani et al.) están verificados directamente contra su fuente original y se citan por nombre como comparadores aplicados en el cuerpo del documento. Los 35 estudios restantes, incluido Gupta et al. —cuya cifra (79,79 %) es numéricamente próxima al resultado del modelo de referencia histórico de este trabajo (79,66 %)—, permanecen pendientes de verificación individual contra su artículo original y, en consecuencia, no se citan por nombre en el cuerpo del documento como comparadores confirmados; se conservan en este anexo con su estado de verificación explícito, sin que la proximidad numérica de ninguna cifra se haya usado como criterio de comparabilidad.

Anexo J. Incidencia de despliegue en Cloud Run (servicio run-model)

Esta incidencia se detectó y corrigió en una sesión de trabajo del 24 de septiembre de 2026, posterior al cierre de la redacción de los capítulos de este documento. Se documenta aquí como evidencia operativa complementaria, con el mismo criterio de verificación aplicado al resto del proyecto: se describe únicamente lo observado y corregido directamente en esa sesión, sin generalizar ni completar por extrapolación ninguna información no confirmada.

El servicio de inferencia desplegado en Cloud Run, identificado como run-model, devolvía errores de tipo 503 al recibir peticiones de clasificación. El diagnóstico realizado en esa sesión atribuyó el fallo a que el contenedor, con una asignación de memoria de 4 GiB, ejecutaba varios procesos trabajadores de Unicorn, cada uno de los cuales cargaba en memoria una copia completa del modelo de clasificación (ResNet50 con ajuste fino). La suma de esas copias agotaba la memoria disponible del contenedor, provocando el fallo del servicio.

La corrección aplicada consistió en ampliar la memoria asignada al contenedor a 8 GiB, limitar la concurrencia a una petición simultánea por instancia y fijar a uno el número de procesos trabajadores mediante la variable de entorno WEB_CONCURRENCY, evitando así que se cargasen varias copias del modelo dentro del mismo contenedor:

```
gcloud run services update run-model \
```

```
--memory=8Gi \
```

```
--concurrency=1 \
```

```
--update-env-vars=WEB_CONCURRENCY=1
```

El correcto funcionamiento del servicio tras esta corrección se verificó mediante la revisión desplegada run-model-00062-p5z y una comprobación de estado sobre el endpoint /health, que respondió de forma saludable. No se ha ejecutado en esta sesión ninguna comprobación de carga ni de rendimiento sostenido del servicio más allá de esta verificación puntual de disponibilidad.

Esta observación confirma que, a fecha de la sesión referida, existe un servicio Cloud Run denominado run-model, operativo y en disposición de servir peticiones de inferencia del modelo de clasificación descrito en este trabajo, y que dicho servicio fue diagnosticado y corregido en esa sesión. No se ha establecido en este documento una relación confirmada entre este servicio y los artefactos de despliegue del prototipo histórico de interfaz descritos en el capítulo 5 de esta memoria; ambas observaciones se documentan de forma independiente, sin reinterpretar la una a partir de la otra.

Como material complementario de difusión, en la misma sesión se produjo un vídeo demostrativo (aproximadamente dos minutos, 1080p, con subtítulos incrustados en español e inglés) que muestra, mediante la aplicación cliente de escritorio descrita y verificada por código en el capítulo 5, conectada a este mismo servicio, el flujo de clasificación tanto de la tarea binaria histórica como de la tarea multiclase que constituye el resultado final de este trabajo, incluyendo la visualización de los mapas de explicabilidad Grad-CAM ya descritos en el capítulo 10. El vídeo está disponible en <https://youtu.be/QgTOD3KOTpl>, junto con su título, descripción y marcas de tiempo por capítulo, e incluye un aviso explícito de que la herramienta presentada es de carácter experimental y no constituye un dispositivo de diagnóstico médico, en línea con las limitaciones ya expuestas en el capítulo 13 de este documento.

El contenido de este anexo es de naturaleza operativa y de divulgación; no introduce ningún resultado experimental adicional ni modifica ninguna de las cifras, tablas o figuras ya presentadas en los capítulos 1 a 14 de esta memoria.